

Análise Estrutural de Sentimentos sobre Entidades em Eventos utilizando Redes Bipartidas com Sinais

Pedro Henrique Silva Oliveira

pedrohso7@github.com

INF 791 - Tópicos Especiais II - Redes Complexas

Universidade Federal de Viçosa (UFV), Brasil

ABSTRACT

Este artigo final descreve uma metodologia estruturada para análise de sentimentos em eventos utilizando o modelo de Redes Bipartidas com Sinais. Com dados oriundos de logs de avaliações voluntárias extraídas da plataforma myMobiConf, exploramos como as redes unipartidas sinalizadas projetadas revelam bolhas de opiniões de participantes, polarização sobre aspectos e heterogeneidade de interação que métricas percentuais globais (como o Net Sentiment Score) ignoram ou enviesam, oferecendo um diagnóstico topológico profundo de eventos e experiências sociais.

KEYWORDS

Redes Bipartidas Sinalizadas, Análise de Sentimentos, Gephi, Eventos Acadêmicos, myMobiConf

1 INTRODUÇÃO E MOTIVAÇÃO

O gerenciamento de eventos acadêmicos e corporativos modernos tem se apoiado em soluções móveis e ubíquas como a plataforma **myMobiConf** [10]. O myMobiConf é um sistema ciente de contexto e distribuído, desenvolvido para auxiliar na organização de eventos e conferências acadêmicas, empresariais e tecnológicas, buscando proporcionar uma experiência mais interativa e eficiente [11]. A plataforma é composta por três módulos principais: um aplicativo móvel para os participantes, um dashboard web destinado aos organizadores, e um backend responsável pelo processamento e integração dos dados. Durante o evento, o sistema coleta feedbacks e avaliações dos participantes, os quais enviam opiniões textuais voluntárias sobre diversos aspectos, tais como palestrantes, sessões, internet Wi-Fi ou coffee break. Essa dinâmica gera um volume massivo de dados qualitativos. No estágio pós-evento, são realizadas análises que resultam em uma série de relatórios, como relatórios de comentários narrativos, análises de questionários e diagnóstico das programações. Embora o sistema preserve a privacidade por meio da descaracterização dos dados, é possível correlacionar as diferentes manifestações enviadas pelo mesmo usuário anônimo ao longo do evento através de seu identificador de sessão.

Tradicionalmente, a análise de feedback de eventos na indústria baseia-se fortemente em métricas agregadas univariadas. O **Net Sentiment Score (NSS)** [12, 14], por exemplo, condensa a saúde do evento em uma fórmula baseada puramente em volume:

$$NSS = \frac{\text{Positivos} - \text{Negativos}}{\text{Total de Comentários}} \times 100 \quad (1)$$

Apesar de sua utilidade para benchmarking gerencial, a literatura de mineração de opinião alerta que abordagens focadas apenas em polaridade global mascaram a natureza multifacetada das avaliações humanas [7, 15]. O NSS e médias estatísticas similares incorrem no que podemos classificar como "achatamento topológico": ao reduzir milhares de interações a um único valor percentual, o modelo destrói a rica rede subjacente de opiniões. Caso um evento receba 50% de avaliações extremamente positivas e 50% extremamente negativas, o NSS resultante será neutro (0), ocultando uma polarização severa que exigiria atenção imediata dos organizadores.

Sob a ótica da Teoria de Redes Complexas [1, 8], um evento é um ecossistema altamente conectado, onde as avaliações formam naturalmente um grafo bipartido entre participantes e aspectos do evento. Ao ignorar essa premissa estrutural, as métricas tradicionais falham em responder perguntas essenciais sobre a dinâmica de feedback:

- (1) **Heterogeneidade de Usuários e Lei de Potência:** A literatura de redes sociais estabelece que a participação de usuários frequentemente segue distribuições de cauda longa [4]. Assim, é preciso entender se a insatisfação de um evento partiu de dezenas de participantes independentes que comentaram uma única vez, indicando uma falha sistêmica, ou se foi distorcida por um único usuário supercrítico que enviou múltiplos feedbacks isoladamente.
- (2) **Formação de Bolhas de Opinião e Homofilia:** As avaliações não ocorrem no vácuo. Participantes que vivenciam os mesmos problemas tendem a expressar sentimentos semelhantes, formando comunidades estruturais. Os modelos percentuais são cegos para agrupamentos de usuários que compartilham percepções convergentes.
- (3) **Correlação Estrutural e Contaminação de Aspectos:** A literatura de Análise de Sentimentos Baseada em Aspectos enfatiza a necessidade de desvincular o sentimento por tópico [16]. É fundamental investigar se a

avaliação negativa de uma infraestrutura, por exemplo, o Wi-Fi, está topologicamente correlacionada à percepção negativa de outras entidades, como a organização do evento, indicando uma contaminação da experiência global.

Diante das limitações inerentes ao achatamento topológico, argumentamos que a dependência exclusiva de agregadores percentuais é metodologicamente insuficiente para compreender o comportamento social e estrutural em eventos.

Para superar essa barreira, este trabalho propõe a hipótese de que as manifestações de sentimentos em um evento formam intrinsecamente uma rede complexa bipartida sinalizada. Postulamos que a projeção e a topologia dessa rede revelam padrões cruciais da dinâmica do evento, incluindo a real heterogeneidade de engajamento dos usuários, a formação de bolhas de opiniões homofílicas e a correlação topológica entre os aspectos avaliados. Tais fenômenos estruturais permanecem invisíveis e indetectáveis pelas métricas estatísticas tradicionais.

O projeto é orientado por cinco Questões de Pesquisa centrais aplicadas ao conjunto de dados de cada evento:

- **QP1 (Concentração e Polarização):** Quais entidades de um evento concentram a maior carga de sentimentos positivos, negativos ou neutros, e qual é o saldo estrutural de sentimento de cada uma?
- **QP2 (Heterogeneidade dos Usuários):** Como se distribui o volume de feedback por usuário? A atividade de feedback é pulverizada de forma homogênea ou dominada por poucos super-usuários engajados?
- **QP3 (Bolhas de Opinião Compartilhada):** É possível agrupar os usuários em comunidades baseando-se unicamente na similaridade de suas percepções sobre as mesmas entidades (projeção unipartida de usuários)?
- **QP4 (Correlação Estrutural de Aspectos):** Quais entidades ou serviços do evento tendem a ser avaliados conjuntamente pelos mesmos participantes, revelando padrões de dependência de experiência (projeção unipartida de entidades)?
- **QP5 (Sentimento Geral do Evento):** Como o sentimento geral e agregado do evento (NSS Global tradicional de mercado) se comporta e se compara com as métricas estruturais do grafo?

2 TRABALHOS RELACIONADOS

A modelagem estrutural de sentimentos utilizando a teoria de redes complexas é uma abordagem moderna. O artigo base de Nonaka e Perry (2026) [9], *"Evaluating LLM Story Generation through Large-scale Network Analysis of Social Structures"*, propôs analisar a estrutura narrativa de histórias geradas por IA modelando-as como redes unipartidas sinalizadas de personagens. Suas métricas avaliam o viés de modelos de linguagem (LLMs) em criar histórias excessivamente lineares e amigáveis, demonstrando a utilidade analítica das redes sinalizadas para caracterizar tendências qualitativas de dados de linguagem natural.

Enquanto Nonaka e Perry (2026) [9] trabalham com grafos unipartidos de interações de personagens fictícios, este projeto estende o conceito para **Redes Bipartidas com Sinais** formadas por feedbacks de eventos do mundo físico. A natureza do myMobiConf exige mapear as interações assimétricas entre **Usuários** (que comentam) e **Entidades** (palestrantes, infraestrutura, organização), aplicando projeções unipartidas sinalizadas em ambos os conjuntos para identificar bolhas de opinião de participantes (projeção de usuários) e agrupamento de dependência de aspectos (projeção de entidades).

3 METODOLOGIA

A modelagem baseia-se na extração de entidades e sentimentos dos logs de comentários salvos de cada evento, seguindo um fluxo metodológico estruturado em oito etapas sequenciais:

- (1) **Etapla 1: Extração de dados:** Carga e caracterização descritiva dos dados reais de logs obtidos de cada evento.
- (2) **Etapla 2: Limpeza e Pré-processamento:** Deduplicação, descarte de nulos e normalização léxica básica de caixa de texto.
- (3) **Etapla 3: Divisão de Sentenças (Sentence Splitting):** Segmentação de períodos compostos e orações independentes para isolamento semântico.
- (4) **Etapla 4: Extração de Aspectos:** Identificação de termos substantivos via POS tagging (spaCy) e agrupamento semântico de termos por embeddings de sentenças.
- (5) **Etapla 5: Análise de Sentimento:** Classificação contínua do sentimento de cada oração no intervalo $-1, 1$ baseada na contagem de termos polarizados.
- (6) **Etapla 6: Modelagem da Rede Bipartida Sinalizada:** Construção do grafo bipartido direcionado com pesos de arestas representando sentimentos médios.
- (7) **Etapla 7: Projeções de Redes Unipartidas:** Geração matemática e topológica das redes de relacionamento de usuários e de aspectos.
- (8) **Etapla 8: Análise Topológica:** Segmentação de bolhas (Louvain), grau ponderado e comparação NSS vs. sentimentos da rede.

3.1 Extração e Processamento Inicial

A fim de validar a metodologia proposta, foram utilizados dados reais extraídos da plataforma de suporte a eventos myMobiConf [10]. Os comentários foram coletados de forma totalmente anonimizada. Serão realizadas análises estruturais separadas para cada grafo (evento) a fim de garantir independência de contexto, validação de perfis de engajamento contrastantes (QP2 e QP5), modularidade das bolhas e padrões de co-ocorrência consistentes.

A etapa de Divisão de Sentenças segmenta os feedbacks compostos. Essa divisão aumenta o número de registros, permitindo que um único participante possua múltiplas arestas direcionadas com sentimentos distintos para aspectos diferentes, em vez de uma média neutra.

3.2 Extração de Aspectos e Análise de Sentimento

A extração de aspectos bottom-up garante que mesmo reclamações de baixa frequência sejam registradas e mapeadas no grafo bipartido. O pipeline utiliza o spaCy [5] para POS-Tagging e os embeddings gerados via Sentence-Transformers [13] são submetidos a um agrupamento hierárquico aglomerativo.

Para polaridade das arestas, a abordagem utiliza o LeIA (Léxico para Inferência Adaptada), baseado no VADER [6]. Ele aplica regras para lidar com negações, intensificadores e conjunções adversativas, sendo adaptado ao contexto de eventos com inserção de gírias.

3.3 Modelagem e Projeções das Redes

A rede principal é um Grafo Bipartido Sinalizado e Direcionado $G_{bipartido} = U, E, A, w$. Os pesos $w : A \rightarrow -1, 1$ indicam a intensidade do sentimento.

Deduzimos duas projeções unipartidas sinalizadas a partir deste grafo:

- **Projeção de Usuários (G_{user}):** Conecta usuários se comentaram as mesmas entidades. O peso representa a concordância média de suas opiniões sobre essas entidades.
- **Projeção de Entidades (G_{entity}):** Conecta entidades se foram comentadas pelos mesmos usuários. O peso representa o saldo de co-avaliação e correlação estrutural dos aspectos.

Posteriormente, os grafos foram exportados no formato GEXF [2] para análise no software Gephi.

4 RESULTADOS E DISCUSSÃO

Abaixo apresenta-se um panorama geral dos critérios aplicados:

- **QP1:** Analisada por Grau de Entrada e Grau Ponderado.
- **QP2:** Analisada via Distribuição de out-degree [1].
- **QP3:** Bolhas de opinião extraídas via Comunidades Louvain em G_{user} (Homofilia [4]).
- **QP4:** Correlação estrutural (Módulos Semânticos [3]) em G_{entity} .

4.1 Análise do Evento 2 (Engajamento Muito Alto)




Figure 1: Rede Bipartida Sinalizada - Evento 2.

Neste evento (464 nós, 1.481 arestas), os hubs mais comentados foram Organizacao (grau=157), Mulheres (grau=112) e Palestra (grau=109). A atividade de usuários seguiu uma cauda longa típica de redes complexas, sendo que a heterogeneidade dividiu o evento em 18 bolhas (Louvain) na projeção unipartida.




Figure 2: Subgrafo do Hub "Mulheres" no Evento 2.

O nó representativo de "Mulheres" revelou um fluxo coeso e homofílico, demonstrando forte consenso de satisfação compartilhada e fechamento focal na comunidade analisada [4].

4.2 Análise do Evento 3 (Engajamento Alto)




Figure 3: Rede Bipartida Sinalizada - Evento 3.

Com 227 nós e 581 arestas, a concentração apontou para Secom (grau=54) e Minicurso (grau=45). O algoritmo detectou 7 bolhas de opinião na rede, concentrando a percepção da audiência em blocos maciços homogêneos.

4.3 Discussão Comparativa

O modelo superou métricas convencionais (NSS Global) identificando ilhas de satisfação local ocultas por médias estatísticas e protegendo o resultado contra o viés de superusuários críticos pontuais que derrubam a avaliação da percepção geral nas métricas convencionais.

5 CONSIDERAÇÕES ÉTICAS

A calibração de dados sintéticos para modelagem obedeceu regras contra o viés de otimismo irreal exposto por Nonaka & Perry (2026) [9], enquanto os feedbacks anonimizados preservaram a privacidade através de identificadores opacos (UIDs) nas simulações.

6 CONCLUSÃO

Este projeto estabeleceu uma abordagem metodológica robusta para modelar feedbacks na plataforma myMobiConf usando Redes Bipartidas com Sinais. Ao extrair os componentes de projeção unipartida, as bolhas de opinião, os nós focais de dependência e as correlações homofílicas, foi provado que o engajamento humano revela uma complexidade analítica muito superior e mais precisa do que os agregadores percentuais unidimensionais de mercado.

REFERENCES

- [1] Albert-László Barabási. 2016. *Network Science*. Cambridge University Press.
- [2] Mathieu Bastian, Sebastien Heymann, and Mathieu Jacomy. 2009. Gephi: an open source software for exploring and manipulating networks. In *Proceedings of the International AAAI Conference on Web and Social Media*, Vol. 3. 361–362.
- [3] Vincent D Blondel, Jean-Loup Guillaume, Renaud Lambiotte, and Etienne Lefebvre. 2008. Fast unfolding of communities in large networks. *Journal of statistical mechanics: theory and experiment* 2008, 10 (2008), P10008.
- [4] David Easley and Jon Kleinberg. 2010. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press.
- [5] Matthew Honnibal and Ines Montani. 2017. spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing. (2017).
- [6] Clayton J Hutto and Eric E Gilbert. 2014. VADER: A parsimonious rule-based model for sentiment analysis of social media text. In *Proceedings of the International AAAI Conference on Web and Social Media*, Vol. 8. 216–225.
- [7] Bing Liu. 2012. Sentiment analysis and opinion mining. *Synthesis lectures on human language technologies* 5, 1 (2012), 1–167.
- [8] Mark EJ Newman. 2018. *Networks*. Oxford university press.
- [9] H. Nonaka and K. E. Perry. 2026. Evaluating LLM Story Generation through Large-scale Network Analysis of Social Structures. (2026).
- [10] Pedro Henrique Silva Oliveira, T. R. M. B. Silva, and F. A. Silva. 2024. Uma Solução de Localização e Navegação Interna para o Sistema myMobiConf. In *Anais do XVI Simpósio Brasileiro de Computação Ubíqua e Pervasiva (SBCUP 2024)*. SBC.
- [11] M. N. Peixoto and T. R. M. B. Silva. 2026. Implementação de uma galeria de fotos do evento com foco em eficiência de comunicação e armazenamento de imagens para o sistema mymobiconf.
- [12] Frederick F Reichheld. 2003. The One Number You Need to Grow. *Harvard business review* 81, 12 (2003), 46–55.
- [13] Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *arXiv preprint arXiv:1908.10084* (2019).
- [14] A. E. Reyes-Mata et al. 2024. Prioritizing the Net Sentiment Score: A Banking Industry Case Study. *The Andhuac Journal* 24, 1 (2024), 84–106.
- [15] Maite Taboada, Julian Brooke, Milan Tofloski, Kimberly Voll, and Manfred Stofellos. 2011. Lexicon-based methods for sentiment analysis. *Computational linguistics* 37, 2 (2011), 267–307.
- [16] Chuhan Wu et al. 2020. A survey on aspect-based sentiment analysis. *arXiv preprint arXiv:2011.02678* (2020).