

Análise de Fidedignidade de Relatórios Narrativos via Agentes de IA no Pós-Evento

Pedro H. S. Oliveira¹, Fabrício Silva¹

¹Instituto de Ciências Exatas e Tecnológicas
Universidade Federal de Viçosa - Campus UFV-Florestal (UFV)
Caixa Postal 15.064 – 91.501-970 – Florestal – MG – Brazil

{pedro.oliveira3, fabricio.silva}@ufv.br

Abstract. Summarizing qualitative feedback in events presents a critical challenge for Large Language Models (LLMs): the tendency toward excessive generalization, which suppresses minority critiques in favor of majority sentiment. This paper investigates the impact of different Prompt Engineering strategies (Baseline, Zero-Shot, Few-Shot, Aspect-Based, CoVe, and Map-Reduce) in mitigating information loss. Using a real-world corpus of 500 comments from the myMobiConf event, an independent manual Ground Truth was established to evaluate Thematic Recall and Precision metrics. The results show that single-stage strategies suffer from severe critique suppression. The adoption of the Aspect-Based Summarization strategy presented the best structural trade-off, achieving 100% Recall on minority pain points at a sustainable computational cost, establishing itself as the recommended architecture for production.

Resumo. A sumarização de feedbacks qualitativos em eventos apresenta um desafio crítico para Grandes Modelos de Linguagem (LLMs): a tendência de generalização excessiva, que suprime críticas minoritárias. Este artigo investiga o impacto de diferentes estratégias de Engenharia de Prompt (Baseline, Zero-Shot, Few-Shot, Aspect-Based, CoVe e Map-Reduce) na mitigação da perda de informações. Utilizando um corpus real de 500 comentários do evento myMobiConf, foi estabelecido um Ground Truth manual para avaliar as métricas de Recall Temático e Precisão. Os resultados demonstram que estratégias de estágio único apresentam severa supressão de críticas. A adoção da estratégia de Aspect-Based Summarization (ABS) apresentou o melhor trade-off estrutural, alcançando 100% de Recall nas dores minoritárias a um custo sustentável, consolidando-se como a arquitetura recomendada para a produção no sistema myMobiConf.

1. Introdução

O myMobiConf é um sistema ciente de contexto e distribuído, desenvolvido para auxiliar na organização de eventos e conferências acadêmicas, empresariais e tecnológicas, buscando proporcionar uma experiência mais interativa e eficiente [Peixoto and Silva 2026]. A plataforma é composta por três módulos principais: um aplicativo móvel para os participantes, um dashboard web destinado aos organizadores, e um backend responsável pelo processamento e integração dos dados. Durante

o evento, o sistema coleta feedbacks e avaliações dos participantes, gerando um volume massivo de dados qualitativos. No estágio pós-evento, são realizadas análises a respeito desses dados que resultam em uma série de relatórios a respeito do evento:

- Relatórios de comentários: Onde são feitos resumos narrativos dos comentários dos participantes na tentativa de condensar as opiniões dos participantes em um texto. Uma abordagem para diminuir a carga de leitura dos organizadores já que ler todas as opiniões seria inviável.
- Relatórios de questionários: Composto por gráficos, resumos e exemplos das respostas dos participantes registradas ao longo do evento.
- Diagnóstico das programações: Análise de quais atividades os participantes mais se interessaram ou interagiram.

Para a maioria das análises é possível utilizar métodos determinísticos, e com métricas quantitativas palpáveis, entretanto a gestão pós-evento enfrenta um desafio crítico na análise de grandes volumes de dados qualitativos: Embora feedbacks livres forneçam os insights mais valiosos para o planejamento de futuras edições, o custo cognitivo de processar centenas de comentários individuais frequentemente leva a análises superficiais ou à completa negligência desses dados. Nesse contexto, o myMobiConf utiliza modelos de linguagem (LLMs) para transformar dados brutos em resumos narrativos, realizando o que a literatura denomina de Sumarização Abstrativa (Abstractive Summarization). Contudo, essa transição introduz uma problemática metodológica: a opacidade do processo de síntese. A IA não apenas condensa o texto, ela interpreta e prioriza informações baseada em instruções pré-definidas (prompts), o que frequentemente resulta em uma "narrativa higienizada" que omite críticas minoritárias de cauda longa em favor da generalização e coesão gramatical.

O presente artigo tem como objetivo investigar a fidedignidade da sumarização abstrativa de comentários gerada por Agentes de Inteligência Artificial dentro da plataforma myMobiConf. Busca-se analisar como seis diferentes estratégias de Engenharia de Prompt (Baseline, Zero-Shot, Few-Shot, Aspect-Based, CoVe e Map-Reduce) impactam a extração da informação qualitativa. Através da construção rigorosa de um Ground Truth manual, estabelecido via Análise Temática Híbrida, este trabalho inspeciona os textos gerados pelos LLMs para identificar em que medida a IA mascara omissões e avaliar quais arquiteturas mitigam o fenômeno da higienização, preservando as dores reais reportadas pelos participantes.

2. Trabalhos Relacionados

A literatura recente sobre Modelos de Linguagem de Grande Escala (LLMs) tem explorado as profundas vulnerabilidades da sumarização de dados qualitativos do mundo real. Esta seção fundamenta o presente estudo ao mapear como a perda de fidelidade analítica e os vieses de omissão têm sido documentados em cenários de processamento de feedback, e discute como a adoção de estratégias avançadas de orquestração de prompts tenta mitigar essas falhas.

2.1. O Problema da Omissão e o "Achatamento" Narrativo

A aplicação de LLMs na síntese de avaliações e opiniões qualitativas frequentemente incorre no que a literatura denomina "Achatamento Narrativo". Em estudos focados

na sumarização de documentos, constatou-se o problema crítico das inconsistências factuais (alucinações): ao processar textos extensos, os modelos tendem a gerar abstrações fluidas em vez de preservar o conhecimento factual específico, perdendo nuances importantes [Chen et al. 2023]. Esta vulnerabilidade corrobora empiricamente os resultados de "higienização" observados no Baseline de nossa pesquisa, demonstrando que instruções ingênuas falham em extrair problemas estruturais diluídos na base de comentários do evento.

2.2. Viés de Generalização e Sycophancy

Para além da simples omissão, a arquitetura baseada em alinhamento por reforço humano (RLHF) dos LLMs modernos introduz vieses cognitivos profundos. Pesquisas recentes sobre técnicas de engenharia de prompt demonstraram a prevalência do viés de generalização (onde as IAs expandem abstrações isoladas para o todo) e da forte inclinação ao Sycophancy (a tendência de agradar o interlocutor suavizando críticas severas em um tom mais diplomático) em modelos de linguagem [Debnath et al. 2025]. Esta constatação literária embasa a necessidade da nossa investigação em testar a separação estrutural (como o Zero-Shot Estruturado e Few-Shot), forçando o modelo a adotar um papel rigoroso de auditoria para neutralizar o tom polido padrão e extrair a essência das críticas reais.

2.3. Vieses na Automatização Qualitativa e a Necessidade de Ground Truth

A adoção de Inteligência Artificial para tarefas analíticas complexas tem gerado alertas na comunidade acadêmica devido às inconsistências factuais. Investigações indicam que os LLMs podem introduzir distorções e alucinações ao tratar de contextos densos, prejudicando severamente a validade metodológica da inferência [Subramanian et al. 2026]. Esta desconfiança epistemológica relatada na literatura é o exato motivo estrutural pelo qual nosso estudo abdicou de usar abordagens convencionais e IAs para avaliar as próprias IAs (LLM-as-a-Judge). Em vez disso, adotou-se a matriz metodológica de um Ground Truth manual, um "padrão-ouro" extraído fisicamente por humanos, garantindo a integridade absoluta da verificação da taxa de erro e alucinação das arquiteturas testadas.

2.4. Avaliação Sistemática e Benchmarking de Estratégias de Prompt

Estudos recentes têm migrado do foco exclusivo nos "erros" dos LLMs para a avaliação sistemática de como diferentes arquiteturas de instrução (Prompts) influenciam esses erros. Pesquisas de 2025 vêm revisando sistematicamente a eficácia de diferentes estratégias de prompt, confrontando diretamente as abordagens de Zero-Shot, Few-Shot e metodologias mais avançadas [Son et al. 2025]. Tais trabalhos demonstram, por exemplo, que a adição de exemplos (Few-Shot) pode ser contraproducente dependendo da complexidade da tarefa, forçando a IA a focar excessivamente na forma em detrimento do conteúdo (fenômeno que embasa o nosso achado sobre o "viés de mimetização").

Nosso estudo se alinha fortemente a esta frente da literatura ao orquestrar um benchmark estrutural conciso (6 estratégias). Entretanto, diferentemente da maioria dos trabalhos que avaliam o desempenho das estratégias utilizando métricas automáticas como ROUGE ou BERTScore sobre datasets genéricos, nossa pesquisa

avança ao avaliar as estratégias contra uma métrica severa de "Recall de Dores Minoritárias" usando um Ground Truth construído à mão. Adicionalmente, revisões sistemáticas recentes recomendam a exploração de orquestrações de prompt mais controladas para garantir uma sumarização confiável [Farjana et al. 2026]. O presente trabalho contempla diretamente essa premissa através da sua abordagem vencedora (Aspect-Based Summarization em Duas Etapas), validando empiricamente que dividir o pipeline analítico é a defesa definitiva contra a ilusão de conformidade.

2.5. Limitações da Instrução Textual vs. Orquestração Sistêmica

Em cenários de altíssima densidade de contexto, como os 500 comentários simultâneos de nossa amostra empírica, a simples reescrita de prompts esbarra na limitação fundamental da arquitetura dos Transformers. O estudo seminal de Liu et al. [Liu et al. 2024] sobre o fenômeno *Lost in the Middle* provou que os modelos sofrem degradação severa de atenção ao tentar processar informações posicionadas no centro da requisição, independentemente da riqueza do prompt. Para romper este teto cognitivo da camada de atenção, a literatura aponta como solução obrigatória a "Orquestração Sistêmica". O presente artigo contempla e avança essa discussão ao testar empiricamente três famílias sistêmicas contra esse limite de memória: o Map-Reduce [Dean and Ghemawat 2008] para contorno de contexto pelo fatiamento físico da base; a Cadeia de Verificação (CoVe) [Dhuliawala et al. 2023] para indução do raciocínio lógico fatiado intra-prompt; e o Aspect-Based Summarization, um Pipeline de múltiplas chamadas que dissocia completamente a extração factual da tarefa de redação textual.

2.6. A Inadequação do RAG para Sumarização Holística

Outra abordagem metodológica largamente explorada na indústria contemporânea para prover conhecimento externo é a Geração Aumentada por Recuperação (RAG) [Debnath et al. 2025]. Contudo, pesquisas comprovam que a natureza fundamental do RAG, caracterizada pela busca fragmentada de blocos de texto limitados através da similaridade vetorial (Cosine Similarity), o torna intrinsecamente inadequado para cenários de Sumarização Abstrativa Holística. Em uma plataforma pós-evento como o myMobiConf, o objetivo central da inferência não é recuperar a resposta para uma "pergunta específica" em uma base estática imensa, mas sintetizar panoramicamente a totalidade do humor, das tensões e das dores daquele evento específico. O uso da técnica de RAG nesse ecossistema recuperaria apenas os comentários mais similares à query, submostrando fatalmente o sentimento global e mascarando dores de cauda longa, motivo pelo qual o RAG foi conscientemente excluído das orquestrações avaliadas em prol das metodologias sistêmicas que engolem todo o contexto de forma holística.

2.7. Delimitação do Escopo de Orquestrações Avaliadas

Embora a Engenharia de Prompt seja um campo vasto e em constante evolução, o presente estudo delimita intencionalmente seu escopo a um núcleo representativo de seis arquiteturas estruturais (Baseline, Zero-Shot, Few-Shot, Aspect-Based, CoVe e Map-Reduce) focadas na viabilidade de Sumarização Abstrativa em lote para ambientes de produção.

Abordagens de raciocínio lógico em múltiplas etapas, como o Chain-of-Thought (CoT) puro e suas expansões como Tree of Thoughts (ToT) ou Graph of Thoughts (GoT), focam primariamente na resolução iterativa de problemas lógico-matemáticos, mostrando-se menos adequadas metodologicamente do que a Cadeia de Verificação (CoVe) para tarefas narrativas onde o controle rigoroso de alucinação e a extração fidedigna são as prioridades. Da mesma forma, abordagens de Self-Consistency (Consistência Própria via voto majoritário) ou ReAct (Reasoning and Acting) foram excluídas da matriz de avaliação empírica. Enquanto o ReAct demanda a interação iterativa com ferramentas externas (desnecessária para a extração de insights de um dataset fechado de comentários), a Self-Consistency exige múltiplas inferências simultâneas da mesma avaliação que multiplicam exponencialmente o custo (tokens), inviabilizando o trade-off operacional. Assim, a contribuição do artigo foca estritamente nas orquestrações que manipulam a janela de contexto para viabilizar técnica e financeiramente a condensação de narrativas qualitativas.

3. Metodologia

Esta etapa do estudo, fundamentada na fase de Techniques (T) do framework PRE-TAR, propõe-se a explorar o eixo central da engenharia de prompts. A investigação avalia como diferentes abordagens cognitivas impostas aos modelos de linguagem moldam o conteúdo final a partir de uma mesma base de dados. O foco recai sobre a análise de fidelidade de extração semântica, buscando identificar, através de inspeção sistemática, quais arquiteturas preservam as nuances originais do evento e quais introduzem distorções estatísticas ou narrativas.

3.1. Definição da Amostra de Estresse e Modelos Utilizados

Para conduzir o experimento de forma a provocar propositalmente o fenômeno do Lost in the Middle (onde a IA ignora dados sob alta carga), estabeleceu-se um dataset único e denso. Foram extraídos e anonimizados 500 comentários reais de uma única instância da plataforma myMobiConf. Esse volume massivo atua como uma "variável de estresse constante", garantindo que todas as abordagens de prompt sejam testadas sob o rigor máximo da janela de contexto (Context Window).

Para isolar a variável da arquitetura de prompt e garantir que as discrepâncias nos resultados não sejam causadas pela diferença de capacidade bruta entre as inteligências artificiais, todo o experimento foi conduzido fixando-se um único modelo estado-da-arte como motor base de inferência: o GPT-4o (disponibilizado via API Github Models). Isso garante que qualquer ganho ou perda de Recall na extração qualitativa seja mérito exclusivo da técnica de injeção de contexto.

3.2. Matriz de Engenharia de Prompt (Benchmark)

Com o objetivo de auditar o comportamento semântico e mitigar vieses algorítmicos (como o Sycophancy e o Viés de Positividade inerentes ao RLHF), o dataset de 500 comentários foi processado de forma independente por seis abordagens concorrentes de Prompt Engineering:

- Abordagem 1 (Controle/Baseline): O prompt padrão em uso no sistema ("Analise estes comentários... e gere um parágrafo..."), com forte restrição de tamanho (400 caracteres), avaliando o achatamento narrativo puro.

- Abordagem 2 (Zero-Shot Estruturado): Adição da técnica de Assunção de Papel (Role-Prompting) e quebra forçada de resposta em duas seções textuais (“Pontos Positivos” e “Críticas”). Busca avaliar se a estruturação semântica resolve o problema.
- Abordagem 3 (Few-Shot Prompting): Injeção de gabaritos prévios na janela de contexto antes da instrução real. Testa se a provisão de exemplos de alta qualidade força o modelo a mimetizar a fidedignidade, ou se ele apenas engessa o formato.
- Abordagem 4 (Aspect-Based / Preservação Factual): Implementação de um Pipeline em Duas Etapas sistêmicas. A primeira chamada extrai rigorosamente os problemas; o prompt secundário incorpora a lista gerada de forma injetada (Knowledge-Preserving).
- Abordagem 5 (Cadeia de Verificação / CoVe): Raciocínio intra-prompt. Força a IA a executar passos lógicos antes da saída: (1) Sintetizar problemas, (2) Redigir o rascunho e (3) Auditar o rascunho contra a síntese para corrigir omissões de forma autônoma.
- Abordagem 6 (Processamento em Lotes / Map-Reduce): Fracionamento sistêmico da carga de estresse. O dataset de 500 comentários é quebrado em lotes menores, processados isoladamente, e aglutinados em uma etapa final para forçar o contorno físico da perda de contexto.

3.3. Protocolo de Avaliação Analítica (Expert Review)

Para operacionalizar a investigação e mensurar o impacto dos resumos gerados, adotou-se o método de Inspeção de Software e Análise de Conteúdo Qualitativa. Os autores realizaram a confrontação sistemática cruzando a base de dados de estresse contra os 6 outputs gerados pelos modelos. A inspeção adotou quatro critérios de matriz categorial:

1. Taxa de Omissão (Higienização): Verifica se a IA ocultou ou removeu menções a atritos técnicos, reclamações ou sugestões de melhoria presentes nos comentários originais, enviesando o relato.
2. Alucinação Narrativa: Identifica a inserção de fatos, elogios genéricos ou informações contextuais que não existiam no dataset.
3. Distorção de Sentimento e Tom: Analisa o “achatamento” emocional do texto, ou seja, se a IA transformou uma crítica severa em uma observação branda ou inofensiva.
4. Custo Cognitivo e Operacional (Tokens/Latência): Dimensiona o volume de processamento necessário e o tempo de resposta em cada estratégia, mensurando o trade-off de viabilidade técnica.

Esta matriz de avaliação permite diagnosticar de forma exaustiva como as seis arquiteturas fundamentais da literatura de prompts comportam-se sob estresse empírico, revelando a melhor solução de integração sistêmica para plataformas qualitativas.

3.4. Abordagem Qualitativa e Ferramenta de Codificação (Taguette)

Para a estruturação analítica dos feedbacks qualitativos e a consequente construção do Ground Truth (Padrão-Ouro), adotou-se uma abordagem de Análise Temática

Híbrida [Braun and Clarke 2006]. Esta abordagem combina a codificação dedutiva (orientada pelos objetivos do estudo em avaliar o recall das dores de cauda longa) com a codificação indutiva (permitindo que novas percepções emergjam diretamente do relato das participantes).

A operacionalização metodológica da codificação foi realizada por meio do software livre Taguette, uma ferramenta dedicada de Análise de Dados Qualitativos (QDA). O conjunto de comentários brutos anonimizados foi importado para a plataforma. Os pesquisadores realizaram a leitura sistemática do material, analisando o escopo semântico de cada feedback e associando-os de maneira rigorosa à árvore hierárquica de categorias. Esse processo meticuloso permitiu a construção de um Ground Truth altamente confiável para a avaliação do comportamento dos Modelos de Linguagem.

3.5. Definição das Macro e Micro-Categorias de Análise

A categorização sistemática dos 500 comentários brutos no Taguette resultou na consolidação de seis macro-categorias principais e suas respectivas subcategorias. A distribuição foi estruturada em dois eixos metodológicos de análise, refletindo aspectos positivos e negativos do evento:

Eixo 1: Aspectos Positivos e Elogios (Fortalezas)

1. Clima e Experiência Coletiva (361 comentários): Reúne a percepção subjetiva e o impacto emocional do evento na comunidade. Divide-se em:
 - Satisfação Geral (347 comentários): depoimentos de apreço positivo, parabenizações e agradecimento geral pela experiência;
 - Inspiração (8 comentários): relatos destacando a motivação profissional e de carreira estimulada pelo evento;
 - Acolhimento (8 comentários): expressões que ressaltam o sentimento de sororidade, união e representatividade feminina.
2. Conteúdo e programação (120 comentários): Aborda os aspectos técnico-científicos das atividades promovidas. Compreende:
 - Palestrantes (79 comentários): avaliações e reações à oratória e conteúdo das palestras principais;
 - Sessões Técnicas (33 comentários): feedbacks voltados às apresentações orais de artigos de pesquisa;
 - Pôsteres (11 comentários): considerações sobre a exposição e discussão dos trabalhos científicos.
3. Gamificação / Engajamento (27 comentários): Avalia a adesão, dinâmica das atividades interativas e o suporte digital. Engloba:
 - Dinâmicas (8 comentários): missões reais no aplicativo e sorteios de brindes;
 - Disponibilidade de Brindes (18 comentários): comentários sobre a satisfação ao ganhar prêmios físicos como camisas e pulseiras;
 - Suporte Organizacional do App (2 comentários): facilitação na navegação através do app oficial.

4. Debates sobre o tema do evento (36 comentários): Mapeia as discussões de cunho social levantadas. Divide-se em:
 - Barreiras de Gênero na Tecnologia (33 comentários): representatividade feminina na Tecnologia e relatos sobre exclusão;
 - Maternidade e Ciclo de Vida (3 comentários): discussões sobre maternidade e ciclo de vida conjugal.

Eixo 2: Críticas, Atritos e Problemas Operacionais (Fragilidades)

5. Conforto, logística e operacional (5 comentários): Reúne queixas reais sobre infraestrutura física, fluxo do local e materiais. É composto por:
 - Credenciamento (1 comentário): fila gerada por gargalo na leitura do QR Code;
 - Espaço Físico (1 comentário): layout físico e tumulto na circulação;
 - Escassez de brindes (2 comentários): esgotamento precoce de brindes temáticos;
 - Climatização (1 comentário): queixa sobre o frio excessivo no auditório principal.
6. Problemas no aplicativo (2 comentários): Avalia bugs e falhas reais no sistema móvel. Divide-se em:
 - Bug de Agenda (1 comentário): dificuldade reportada ao adicionar atividades na agenda;
 - Bug de Questionário (1 comentário): erro ao responder itens de formulário no aplicativo.

A partir desta divisão qualitativamente refinada, isolou-se as dores minoritárias de cauda longa (Eixo 2) para servir de teste de estresse contra a higienização algorítmica dos LLMs. A avaliação baseou-se especificamente na capacidade de detecção unânime dos seguintes seis problemas estruturais mapeados:

- Agenda (Problemas no aplicativo): Dificuldade ao adicionar missões na agenda.
- Questionário (Problemas no aplicativo): Erro ao preencher formulários pelo app.
- Escassez de brindes (Conforto, logística e operacional): Esgotamento de materiais.
- Espaço Físico (Conforto, logística e operacional): Tumulto físico.
- Credenciamento (Conforto, logística e operacional): Fila de leitura de QR Code.
- Climatização (Conforto, logística e operacional): Auditório principal excessivamente frio.

4. Estudo de Caso e Execução do Experimento

Com a metodologia definida, procedeu-se à execução do estudo de caso para avaliar na prática a geração e o impacto dos resumos narrativos. O experimento foi conduzido em três fases sequenciais: a coleta e seleção dos dados na plataforma, a geração automatizada dos resumos utilizando as configurações de IA definidas através da API da plataforma, e finalmente a inspeção analítica conduzida pelo autor principal e revisada pelo co-autor especialista em dados.

4.1. Desenho Experimental

O experimento foi estruturado para tensionar ao máximo o limite de atenção (Context Window) dos modelos avaliados. Para garantir a manifestação do fenômeno de Lost in the Middle, em que a IA silencia ou descarta informações relevantes por exaustão de processamento, o estudo fixou a "Carga Cognitiva" no dataset de estresse máximo: uma base contendo exatamente 500 comentários brutos de avaliação de evento.

Sob este teto de carga extrema, a variável central de investigação tornou-se o Esforço de Arquitetura de Instrução (Prompt Engineering). A base de dados foi processada simultaneamente sob seis diferentes abordagens metodológicas de extração: Controle, Zero-Shot, Few-Shot, Two-Stage Pipeline (Aspect-Based), CoVe (Chain-of-Verification) e Processamento em Lotes (Map-Reduce). Esta abrangência permitiu um embate metodológico sem precedentes na avaliação de dados de feedback.

Na sequência, a infraestrutura da API Node.js do myMobiConf foi adaptada para expor seis endpoints distintos, responsáveis por orquestrar as requisições para as diferentes estratégias de sumarização em um único motor LLM (Modelo Estado-da-Arte, via API). Notavelmente, a arquitetura do backend encarregou-se de coordenar nativamente o raciocínio complexo: o endpoint do Aspect-Based executou o encadeamento das duas etapas de requisição; o endpoint do CoVe implementou as três chamadas lógicas de autocrítica; e o endpoint do Map-Reduce realizou o particionamento assíncrono dos 500 comentários e o resumo final.

4.2. Inspeção e Confrontação de Dados

Após a obtenção dos resumos gerados, o material foi submetido à Avaliação Heurística preliminar pelo autor principal, sendo os resultados posteriormente validados pelo co-autor especialista na área de dados. Os arquivos .csv com os comentários anonimizados foram processados através da API, garantindo a integração direta com o serviço de inferência do LLM na nuvem.

O momento crítico do experimento ocorreu no contraste direto entre o dado bruto e a síntese da máquina. A aplicação da matriz de fidelidade narrativa expôs imediatamente as discrepâncias e escolhas interpretativas tomadas pelos agentes de IA. Observou-se, de antemão, uma forte tendência dos modelos genéricos em suavizar problemas técnicos reportados, um fenômeno diretamente atrelado à restrição de tamanho imposta pelo prompt inicial.

4.3. Refinamento do Prompt

O avanço na utilização de Modelos de Linguagem de Grande Porte (LLMs) em sistemas de produção exige que a interface de instruções (prompt) não seja tratada apenas como uma linha de comando textual estática, mas como uma variável metodológica dinâmica que dita a qualidade e confiabilidade do processamento do modelo [Son et al. 2025]. No contexto da plataforma myMobiConf, o prompt de sumarização pós-evento atualmente empregado na API de produção é estruturado conforme a seguinte definição:

”Analise estes comentários sobre um evento e gere um parágrafo de no máximo 400 caracteres único que englobe: 1. Comece diretamente com os pontos mais elogiados (organização, atividades, estrutura) 2. Em seguida mencione críticas ou sugestões quando relevantes 3. Seja objetivo, sem frases como ‘os comentários destacam’ 4. Mantenha tom profissional e imparcial.”

Apesar de sua aparente clareza e concisão, uma análise fundamentada na literatura de Engenharia de Prompts e Processamento de Linguagem Natural revela que essa instrução possui vulnerabilidades estruturais que comprometem a fidedignidade da síntese resultante.

4.3.1. Análise Crítica do Prompt Atual na Literatura

A partir do confronto com as melhores práticas de design de instruções identificadas em revisões e pesquisas recentes sobre a otimização de sumarização auxiliada por Inteligência Artificial [Debnath et al. 2025, Son et al. 2025], é possível mapear quatro limitações principais no prompt de produção atual:

1. **Carga Cognitiva Excessiva no Processamento de Instruções Simultâneas:** O prompt atual agrupa a análise qualitativa, a filtragem de relevância, a estruturação narrativa e uma restrição severa de tamanho (limite de 400 caracteres) em uma única instrução corrida. Conforme apontado por Son et al. [Son et al. 2025], a sobrecarga de restrições complexas em um único estágio de inferência prejudica a confiabilidade da IA, aumentando a probabilidade de o modelo priorizar regras sintáticas (tamanho do parágrafo e gramática) em detrimento da acurácia lógica e semântica.
2. **Vulnerabilidade à “Higienização Narrativa”:** Ao exigir que o modelo mescle pontos altamente positivos com críticas em um parágrafo extremamente curto e único, cria-se uma pressão competitiva por espaço de representação. Sob essa restrição, o modelo tende a suavizar ou omitir reclamações complexas em favor de uma generalização harmoniosa. Esse fenômeno, fortemente relacionado ao viés de complacência (sycophancy) e generalização excessiva analisados por Debnath et al. [Debnath et al. 2025], resulta em resumos que geram uma ilusão de conformidade perfeita, silenciando as dissonâncias dos feedbacks originais.
3. **Ausência de Atribuição de Papel (Role-Prompting):** A instrução não define uma persona ou contexto de atuação para a IA. A atribuição de um papel específico (como analista de experiência do usuário ou pesquisador de IHC) é uma técnica fundamental que orienta o espaço semântico e a precisão interpretativa do modelo, melhorando sensivelmente a eficácia da sumarização e a fidedignidade do texto gerado [Son et al. 2025].
4. **Rigidez na Concatenação Narrativa:** A exigência de aglutinar elogios e críticas num único fluxo sequencial e homogêneo dificulta que o modelo expresse contradições inerentes a dados qualitativos qualitativos, favorecendo resumos rasos e reducionistas.

4.3.2. Proposta de Refinamento Baseada em Evidências

Para mitigar a opacidade da síntese e elevar o nível de fidedignidade da narrativa sem sobrecarregar cognitivamente os gestores, a literatura sugere a aplicação de técnicas avançadas de Engenharia de Prompt. A seguir, correlacionam-se as vulnerabilidades identificadas com as diretrizes da literatura e as respectivas técnicas aplicadas para a solução do problema:

- Role-Prompting (Persona Especialista): Define um papel profissional claro para guiar o tom e o rigor das prioridades analíticas da IA [Son et al. 2025]. Aplicado para resolver a Falta de Direção Analítica e a ausência de contexto de atuação do prompt original.
- Separação Analítica (Elogios x Críticas): Obriga o modelo a extrair aspectos positivos e negativos em seções apartadas e obrigatórias, mitigando o sycophancy [Debnath et al. 2025]. Aplicado para resolver a Higienização e Omissão de Críticas importantes que ocorria quando o modelo tentava conciliar múltiplos tons sob restrição extrema de tamanho de um parágrafo único.
- Geração Fiel (Knowledge-Preserving Prompts / Grounding): Restringe a síntese da IA exclusivamente aos depoimentos inseridos como entrada para prevenir inconsistências factuais [Chen et al. 2023]. Utilizado para sanar a Perda de Rastreabilidade e o risco de generalizações abstratas ou alucinações.
- Remoção da Restrição de Tamanho (Length Unbound): Elimina o limite limitante de caracteres (400 caracteres) presente no prompt original, mitigando a pressão competitiva de espaço que forçava o modelo a descartar sistematicamente as reclamações minoritárias.

A aplicação simultânea destas quatro técnicas culminou na primeira arquitetura refinada de instrução da nossa avaliação (o Zero-Shot Estruturado). O prompt resultante abandona a abstração da instrução legada e incorpora materialmente cada técnica literária em blocos textuais específicos (ou na remoção consciente deles):

[Role-Prompting] "Você é um Analista de Qualidade Especialista em Experiência do Usuário (UX) de eventos. Sua tarefa é analisar os comentários qualitativos fornecidos pelos participantes e extrair um relatório narrativo fiel à realidade.

[Remoção da Restrição de Tamanho & Separação Analítica] Estruture sua resposta em duas partes textuais claras: '1. Pontos Positivos e Elogios' e '2. Críticas, Atritos e Sugestões'.

[Geração Fiel / Grounding] Baseie-se estritamente nos dados fornecidos, sem omitir problemas enfrentados pela minoria e sem inventar informações.

IMPORTANTE: Não utilize formatação Markdown sob nenhuma hipótese. O retorno deve ser estritamente em texto puro.

Comentários: [DATASET]"

Esta proposta inicial (Zero-Shot Estruturado) reflete o estado da arte para requisições de Turno Único (Single-Turn Prompting). Contudo, a literatura recente constatou que existe um "teto de vidro" cognitivo que não pode ser superado apenas com o refinamento textual e semântico do prompt. Em seu estudo seminal, Liu

et al. [Liu et al. 2024] demonstraram o fenômeno *Lost in the Middle*: ao avaliar modelos de última geração em tarefas de longa janela de contexto (como analisar centenas de comentários), descobriram que a arquitetura dos Transformers recupera bem informações no início e no fim do texto, mas sofre uma degradação severa de Recall ao tentar acessar dados localizados no meio da requisição, independentemente da clareza da instrução imposta.

O estudo conclui que a melhoria isolada do prompt textual é inócua para impedir a omissão de fatos estruturais sob cargas altas de processamento qualitativo. Para romper esse teto cognitivo, torna-se obrigatória a transição de um paradigma de "instrução de texto" para um paradigma de "arquitetura sistêmica", orquestrando o modelo através de particionamento físico (como o Map-Reduce) ou estágios encadeados de inferência clínica (como o Aspect-Based Summarization e CoVe). É sob esta justificativa teórica que a metodologia do presente trabalho expande a análise para além dos prompts clássicos, testando se a orquestração sistêmica consegue efetivamente recuperar as dores minoritárias perdidas no "meio" do dataset.

A partir dessas diretrizes e da limitação física do modelo comprovada por Liu et al. [Liu et al. 2024], entende-se que um único design de prompt não é suficiente para isolar a causa raiz da higienização narrativa. Portanto, este estudo propõe a evolução metodológica baseada em um benchmark de seis abordagens concorrentes de engenharia:

1. Controle (Baseline): O prompt legado em produção, restritivo e genérico, atuando como parâmetro de controle para a higienização.
2. Zero-Shot Estruturado: Adoção de Role-Prompting e divisão explícita em seções ("Pontos Fortes" e "Críticas"), testando a otimização textual pura.
3. Few-Shot Prompting: Injeção de gabaritos ideais prévios na janela de contexto, testando se o aprendizado em contexto (In-Context Learning) supera a sobrecarga de leitura.
4. Pipeline em Duas Etapas (Aspect-Based): Desacopla a carga cognitiva. Uma primeira chamada extrai problemas; a segunda redige o texto ancorada nestes fatos.
5. Cadeia de Verificação (CoVe): Metodologia inspirada por Dhuliawala et al. [Dhuliawala et al. 2023]. Obriga a IA a sintetizar os dados, redigir o resumo e auditar seu próprio texto contra os dados iniciais para corrigir omissões em um único passo.
6. Processamento em Lotes (Map-Reduce): Padrão arquitetural [Dean and Ghemawat 2008] que fraciona o dataset original em partições menores, processa sub-resumos isolados e realiza um resumo global final, eliminando ativamente o estouro de contexto.

Essa matriz permite não apenas avaliar se o viés de conformidade foi reduzido, mas medir o trade-off de custo computacional (tokens) e complexidade de integração sistêmica necessários para preservar a verdade qualitativa. O impacto dessas seis formulações compõe a base do desenho experimental detalhado nas seções subsequentes.

5. Resultados e Discussão

A execução dos experimentos sob a matriz de estresse cognitivo (500 comentários simultâneos versus seis arquiteturas concorrentes de prompting) revelou comportamentos sistêmicos na forma como Modelos de Linguagem processam tensões qualitativas. A análise cruzada dos relatórios gerados permitiu isolar o fenômeno da “higienização de feedback”, evidenciando que a precisão factual em bases densas depende substancialmente do design sistêmico da instrução, muito além do mero tamanho da janela de contexto.

A Tabela 1 ilustra as discrepâncias narrativas e os compromissos técnicos assumidos por cada arquitetura sob carga extrema.

Tabela 1. Comparativo de Extração de Críticas (Estresse: 500 Comentários)

Arquitetura de Prompt	Comportamento Observado na Extração
1. Controle (Baseline)	Condensou a massa de texto e capturou apenas a escassez de brindes (Recall de 1/6), omitindo falhas graves do aplicativo, credenciamento e climatização.
2. Zero-Shot Estruturado	A remoção de stopwords atenuou o gargalo de contexto, permitindo capturar 5/6 dores. Omitiu apenas o bug de reagendamento de atividades no aplicativo.
3. Few-Shot Prompting	A mimetização estrutural com stopwords atingiu 5/6 dores, mas a rigidez do exemplo omitiu o erro técnico de seleção do questionário.
4. Two-Stage (Aspect-Based)	Mapeou os aspectos na Fase 1 e redigiu ancorado neles. Recall de 100% (6/6) estável em duas chamadas, sem estresse de janela de contexto.
5. CoVe (Cadeia Verificação)	A auditoria de veracidade resgatou 5/6 dores, mas o processo de verificação intra-prompt omitiu o reagendamento e exigiu alto custo de tokens.
6. Map-Reduce (Lotes)	Recall de 100% (6/6) pelo fatiamento físico, mas gerou gargalo de infraestrutura (Rate Limit HTTP 429) e latência operacional inaceitável.

5.1. Omissão e a Ilusão de Conformidade no Baseline

A primeira fase da avaliação debruçou-se sobre a Abordagem 1 (Controle). A análise qualitativa evidenciou um nível severo de degradação da fidelidade narrativa. Ao impor uma restrição rigorosa de tamanho sobre uma vasta massa de dados conflitantes, induz-se o modelo a priorizar tópicos de maior densidade estatística (o sucesso majoritário do evento, as palestrantes principais) em detrimento da cauda longa de problemas. Comparado ao Ground Truth manual, o Baseline omitiu cinco das seis dores minoritárias, citando de forma superficial apenas a necessidade de mais brindes, e homogeneizando falhas críticas de infraestrutura e do aplicativo. Esse achatamento também se manifestou sob a forma de Sycophancy (adulação algorítmica): para neutralizar as tensões qualitativas e caber no limite de caracteres, o modelo atuou como um suavizador de tom, convertendo queixas explícitas em observações vagas como “sugestões de melhorias”. Este fenômeno, corroborado por

Debnath et al. [Debnath et al. 2025], ilustra o perigo da sumarização "ingênua" em produção: ela fornece aos gestores uma perigosa ilusão de conformidade perfeita, mascarando dados vitais para a evolução contínua do produto.

5.2. O Teto Cognitivo e Riscos de Mimetização (Zero-Shot e Few-Shot)

A estruturação semântica do Zero-Shot (Abordagem 2) e o aprendizado em contexto do Few-Shot (Abordagem 3) foram impulsionados pela minificação de stopwords. Ao reduzir a densidade de tokens em 22%, o estresse atencional atenuou-se, mitigando parcialmente o fenômeno do Lost in the Middle (Liu et al., 2024) e permitindo a recuperação de 5/6 dores (anteriormente limitadas a menos de 50% de recall). Contudo, o teto cognitivo persistiu na omissão seletiva de bugs sistêmicos específicos: o Zero-Shot falhou em registrar o bug de reagendamento da agenda pessoal no aplicativo, enquanto o Few-Shot omitiu a limitação no formulário do questionário. Em termos de alucinação, a abordagem Few-Shot mostrou-se altamente vulnerável à indução por formato: para mimetizar a estrutura rígida dos exemplos prévios fornecidos no prompt, o modelo tendeu a generalizar e inventar atritos logísticos (como problemas com coffee break e alimentação) inexistentes na base de dados de estresse. Isto indica que a simplificação de tokens auxilia na compressão e que exemplos guiam a forma, mas falham em garantir completude factual sem a presença de uma trava estrutural.

5.3. Limitações da Autocorreção e Sucesso da Fragmentação (CoVe e Map-Reduce)

Ao confrontarmos as duas abordagens estruturadas mais complexas, identificaram-se comportamentos distintos de recall e fidelidade factual:

- Cadeia de Verificação (CoVe - Abordagem 5): Atingiu 5/6 de recall, falhando no bug de reagendamento do aplicativo. Embora a técnica force o modelo a auditar o rascunho intermediário contra um passo prévio de extração, ela sofre de um gargalo de inicialização: se um aspecto qualitativo de cauda longa for omitido na primeira leitura (Passo 1) devido à sobrecarga de tokens, a etapa subsequente de autocrítica é incapaz de recuperá-lo, pois a veracidade é avaliada contra as notas extraídas, e não contra a base bruta.
- Map-Reduce (Abordagem 6): Atingiu 100% de recall (6/6). O particionamento físico dos 500 comentários em pequenos lotes independentes removeu completamente a pressão sobre a janela de atenção do LLM, permitindo que todas as dores de cauda longa fossem capturadas individualmente e consolidadas no relatório final. Contudo, essa integridade qualitativa não impediu uma leve distorção de tom na fase de consolidação (Reduce), onde o modelo tendeu a agrupar atritos isolados como se fossem reclamações generalizadas de todo o evento.

5.4. Desacoplamento e Preservação Factual (Aspect-Based)

A quebra de paradigma na fidedignidade ocorreu com a transição para a orquestração sistêmica na Abordagem 4 (Aspect-Based). O segredo estrutural foi remover a tarefa de "compor prosa" dos ombros do modelo durante a fase de leitura. Apenas a instrução de extração ("liste os problemas") foi acionada. Liberado da carga cognitiva de formatar texto e buscar coesão, o LLM operou clinicamente e listou com

exatidão cirúrgica as mesmas 6 falhas do Ground Truth manual. Na etapa subsequente do Pipeline, a injeção forçada desta lista atuou como uma "trava lógica". O modelo foi instruído a escrever o relatório final ancorando-se obrigatoriamente nos aspectos extraídos na primeira fase. Esta restrição física barrou a omissão e neutralizou alucinações (falsos positivos), pois o LLM não possuía liberdade gerativa para extrapolar a lista. A arquitetura comprovou que a suposta "falta de inteligência" em prompts longos é, na verdade, um bloqueio de atenção dividida; separando a extração da sumarização, neutraliza-se o silenciamento minoritário.

5.5. Análise de Trade-Offs Operacionais para o myMobiConf

A adoção de LLMs em um ambiente de produção real (myMobiConf) transcende a avaliação puramente qualitativa do texto. O sistema atende múltiplos eventos simultâneos, operando sob restrições técnicas de tempo de resposta e custo de infraestrutura (tokens). A Tabela 2 consolida a análise de trade-off baseada em métricas de engenharia de software em nuvem.

Tabela 2. Matriz de Trade-offs: Abordagens Analíticas para o Sistema myMobiConf

Abordagem	Recall Temático	Latência de Exec.	Custo (Tokens)	Complex. de Eng.
Controle (Baseline)	1/6 (16%)	Muito Baixa	Muito Baixo	Nula (API Única)
Zero/Few-Shot	5/6 (83%)	Baixa	Baixo	Baixa
Map-Reduce	6/6 (100%)	Inviável (Lots)	Alto	Alta (Rede Assíncrona)
CoVe	5/6 (83%)	Moderada	Muito Alto	Média
Aspect-Based	6/6 (100%)	Moderada	Médio	Média (Pipeline Duplo)

Ao confrontarmos os rigorosos modelos de auditoria (Abordagem 5 - CoVe) e de particionamento físico (Abordagem 6 - Map-Reduce), a inviabilidade sistêmica tornou-se evidente. Embora o Map-Reduce pulverize os limites da janela de contexto garantindo leitura fragmentada perfeita, o fatiamento de 500 comentários resultou em uma tempestade de disparos simultâneos contra a arquitetura baseada em API. Isso desencadeou a resposta sistêmica de Rate Limit (HTTP 429 Too Many Requests) e sobrecargas no servidor (HTTP 500). Para contornar os bloqueios de infraestrutura, exige-se a inserção de gargalos artificiais (delays assíncronos) na comunicação de rede, arrastando o tempo de geração do relatório para vários minutos, um fluxo inaceitável para a experiência do usuário final.

Paralelamente, o modelo CoVe garantiu a integridade factual através de etapas intra-prompt de autocrítica, mas o tráfego gerado pela verificação interna fez o consumo de tokens multiplicou-se desnecessariamente, comprometendo o orçamento de inferência. A abordagem Aspect-Based consolidou-se indiscutivelmente como a "Vencedora Operacional": alcançou Recall qualitativo de 100% com a estabilidade de apenas duas requisições consecutivas por relatório.

6. Ameaças à Validade

A condução de estudos empíricos envolvendo Modelos de Linguagem para análise qualitativa está sujeita a variáveis que podem influenciar os resultados. Conforme os padrões de pesquisa em Engenharia de Software, mapeamos as principais ameaças à validade do nosso estudo e as respectivas mitigações adotadas.

6.1. Validade Interna

A principal ameaça à validade interna reside no processo de construção do Ground Truth ("Padrão-Ouro"). Como a catalogação das dores minoritárias foi realizada manualmente pelos autores, existe o risco inerente de viés interpretativo humano durante a leitura dos 500 comentários. Para mitigar esta ameaça, a validação das categorias e do mapeamento semântico foi revisada pelo segundo autor, que atua como especialista do domínio e pesquisador sênior da área, reduzindo o viés de interpretação individual. Além disso, o processo de categorização priorizou a obviedade da dor explícita na semântica do usuário e evitou-se categoricamente o uso de "LLMs como juízes"(LLM-as-a-Judge), isolando a avaliação da taxa de acerto de qualquer contaminação induzida pelas próprias IAs.

6.2. Validade Externa

A validade externa diz respeito à capacidade de generalização dos achados. O dataset empírico utilizado é proveniente de um único evento tecnológico (myMobiConf), limitando a extrapolação irrestrita para eventos de naturezas radicalmente distintas (como entretenimento esportivo ou congressos médicos), cujos comentários podem possuir jargões, gírias e distribuições de sentimento diferentes. Contudo, o limite cognitivo da janela de contexto provado no estudo (Lost in the Middle) é um fenômeno arquitetural dos LLMs, o que sugere que a falência do Baseline e o sucesso da arquitetura Aspect-Based devem se replicar sistematicamente em cenários de alta densidade de dados qualitativos, independentemente do domínio.

6.3. Validade de Construto

A escolha de limitar as métricas analíticas ao Recall Temático e à Latência de Execução pode não capturar todas as facetas da experiência qualitativa (como o tom de voz da resposta gerada ou o conforto linguístico do organizador ao ler o relatório). Contudo, dado que o principal risco de negócios em plataformas de feedback é o "achatamento narrativo"(a falsa sensação de que não houve problemas em eventos defeituosos), priorizar a detecção das falhas (Recall de 100%) é a fundação primária e o construto mais crítico a ser aferido antes de avaliar variáveis estéticas textuais.

7. Disponibilidade de Recursos e Reprodutibilidade

Para garantir a transparência metodológica e a reprodutibilidade empírica do estudo, todos os recursos linguísticos da pesquisa foram organizados estruturalmente nos Anexos deste documento.

Diferente de abordagens focadas apenas em resultados superficiais, documentamos a totalidade dos artefatos empregados:

- Anexo A - Ground Truth Qualitativo Completo: Apresenta o gabarito manual utilizado como Padrão-Ouro da pesquisa, contemplando não apenas os temas majoritários (ex: inspiração, qualidade das palestrantes), mas detalhando categoricamente as 6 "dores minoritárias de cauda longa" (como a escassez de broches, erros no QR Code e temperatura da sala) que parametrizaram a avaliação de Recall.
- Anexo B - Engenharia de Prompts Sistêmica: Cataloga todas as variações arquiteturais de instrução injetadas na API (Baseline, Zero-Shot, Aspect-Based Fase 1 e CoVe), permitindo a replicação exata do "teste de estresse" cognitivo sobre os LLMs.

O cruzamento do Gabarito do Anexo A com as falhas mecânicas explícitas nos códigos do Anexo B constitui a matriz de rastreabilidade que validou a superioridade da orquestração em duas etapas do Aspect-Based Summarization no ecossistema do evento myMobiConf.

Referências

- Braun, V. and Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative research in psychology*, 3(2):77–101.
- Chen, C., Zhang, W. E., Shakeri, A. S., and Fiza, M. (2023). The exploration of knowledge-preserving prompts for document summarisation. *arXiv preprint arXiv:2301.11719*.
- Dean, J. and Ghemawat, S. (2008). Mapreduce: Simplified data processing on large clusters. *Communications of the ACM*, 51(1):107–113.
- Debnath, T., Siddiky, M. N. A., Rahman, M. E., Das, P., Guha, A. K., Rahman, M. R., and Kabir, H. M. D. (2025). A comprehensive survey of prompt engineering techniques in large language models. *TechRxiv*.
- Dhuliawala, S., Komeili, M., Xu, J., Raileanu, R., Li, X., Celikyilmaz, A., and Weston, J. (2023). Chain-of-verification reduces hallucination in large language models. *arXiv preprint arXiv:2309.11495*.
- Farjana, A., Cheng, Z., and Mastropaolo, A. (2026). Prompt-driven code summarization: A systematic literature review. *arXiv preprint arXiv:2604.15385*.
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., and Liang, P. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173.
- Peixoto, M. N. and Silva, T. R. M. B. (2026). Implementação de uma galeria de fotos do evento com foco em eficiência de comunicação e armazenamento de imagens para o sistema mymobiconf.
- Son, M., Won, Y.-J., and Lee, S. (2025). Optimizing large language models: A deep dive into effective prompt engineering techniques. *Applied Sciences*, 15(3):1430.
- Subramanian, S., Narapureddy, R. M., Palanisamy, M. P., Islam, K. A., and Khan, M. A. A. H. (2026). Efficient summarization with lightweight llms through sparse input activation and adaptive prompting. *Applied Computing and Intelligence*, 6(1):58–78.

Material Suplementar (Anexos)

O material suplementar deste artigo, contendo o Ground Truth Manual (Anexo A), o Repositório de Prompts Sistêmicos (Anexo B) e os Extratos Analíticos dos Modelos (Anexo C), está disponível online e pode ser acessado através do link:

<https://drive.google.com/file/d/13BcuqzYhmuEMUFoCX8963vDt-hoSz7HZ/view?usp=sharing>